BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP.HCM
KHOA ĐIỆN - ĐIỆN TỬ



BÁO CÁO CUỐI KỲ

MÔN HỌC: CẤU TRÚC RỜI RẠC

DỰ ĐOÁN THỜI GIAN ÙN TẮC GIAO THÔNG

Giảng viên hướng dẫn: TS. Phan Học
Mã lớp học phần: [UTE] 261DSCC235864_03

Danh sách sinh viên thực hiện:
1. Nguyễn Lê Phúc Thịnh 25139047
2. Nguyễn Tuấn Thịnh 25139048

TP. Hồ Chí Minh, tháng 10 năm 2026

Mục lục

1 Phát biểu bài toán **1**
- 1.1 Mục tiêu và phạm vi . . . 1
- 1.2 Đầu vào và đầu ra . . . 1
- 1.3 Từ đề xuất ban đầu đến hệ thống hiện tại . . . 2

2 Bộ dữ liệu và phương pháp thu thập **3**
- 2.1 Nguồn và quy trình thu thập . . . 3
- 2.2 Quy mô và cấu trúc . . . 3
- 2.3 Phân bố quan sát . . . 4
- 2.4 Chất lượng và tính đại diện . . . 6

3 Quy trình xử lý hệ thống **6**
- 3.1 Luồng xử lý tổng thể . . . 6
- 3.2 Nhận diện phương tiện và tạo phép đo . . . 7
- 3.3 Kiểm tra và tiền xử lý chuỗi thời gian . . . 7
- 3.4 Thiết kế 61 đặc trưng . . . 8
- 3.5 Kiến trúc dự báo và hậu xử lý . . . 9
- 3.6 Khởi động và dự báo tạm thời . . . 10

4 Lựa chọn mô hình và tinh chỉnh siêu tham số **10**
- 4.1 Cơ sở lựa chọn . . . 10
  - 4.1.1 Cơ sở lựa chọn kiến trúc thuật toán (Model Selection) . . . 10
  - 4.1.2 Chiến lược thiết lập không gian siêu tham số (Hyper-parameter Configuration) . . . 11
- 4.2 Phần thực sự được lựa chọn bằng validation . . . 11
- 4.3 Cấu hình hiện tại và ý nghĩa của từng tham số . . . 11
- 4.4 Chia dữ liệu và ngăn rò rỉ thời gian . . . 11
- 4.5 Kết quả so sánh đã lưu . . . 12
- 4.6 Tác động của làm mượt và phiên bản kết quả . . . 13

5 Điểm nổi bật và đóng góp của dự án **13**
- 5.1 Kết nối thị giác máy tính với dự báo chuỗi thời gian . . . 13
- 5.2 Phân biệt dữ liệu thật, tham chiếu và dữ liệu mất . . . 14
- 5.3 Giữ danh tính nguồn dự báo khi người dùng đổi camera . . . 14
- 5.4 Xử lý bất đồng bộ và lưu bằng chứng trước khi biết tương lai . . . 14
- 5.5 Kiểm tra tính tương thích và bảo vệ model đang dùng . . . 14
- 5.6 Kiểm thử hướng vào lỗi có ý nghĩa . . . 15

6 Bài học kinh nghiệm **15**
- 6.1 Định nghĩa đúng đại lượng trước khi tối ưu mô hình . . . 15
- 6.2 Không có ô trống không có nghĩa chuỗi liên tục . . . 15
- 6.3 Baseline phải phù hợp với cấu trúc dữ liệu . . . 15
- 6.4 Đường dự báo đẹp và cảnh báo hữu ích là hai mục tiêu khác nhau . . . 15
- 6.5 Bảo toàn thứ tự thời gian cả trong học và chấm điểm . . . 15
- 6.6 Quản lý phiên bản là một phần của độ tin cậy . . . 16
- 6.7 Ưu tiên cho vòng phát triển tiếp theo . . . 16

A Mã nguồn (Source Codes) **17**
- A.1 Các thư viện được sử dụng . . . 17
- A.2 Get_frame.py . . . 17
- A.3 Yolo_detect.py . . . 17

1 Phát biểu bài toán

1.1 Mục tiêu và phạm vi

Dự án nghiên cứu khả năng sử dụng ảnh camera tại khu vực Ngã Tư Hàng Xanh để theo dõi mức hiện diện của phương tiện và ước lượng thời gian đến một trạng thái đông xe. Hệ thống chuyển ảnh thành số đếm theo loại phương tiện, xây dựng chuỗi thời gian, dự báo diễn biến trong một giờ tiếp theo và trình bày kết quả trên ứng dụng desktop.

Phiên bản đã triển khai giải quyết một bài toán cụ thể: dự báo chỉ số WTI trung bình từng phút trong 60 phút tiếp theo, sau đó xác định thời điểm bắt đầu cửa sổ vượt ngưỡng WTI thử nghiệm. Đây là hệ thống nguyên mẫu phục vụ nghiên cứu. Tập dữ liệu chưa có nhãn ùn tắc độc lập, tốc độ dòng xe hoặc thời gian hành trình để xác nhận trạng thái ùn tắc ngoài thực tế.



Hình 1: Ảnh hiển thị chế độ MODEL WTI với 61 phút quan sát thật, WTI trung bình trượt 122,5 và trạng thái đang vượt ngưỡng. Trục hiển thị hai giờ trước và hai giờ sau hiện tại; phần dự báo chỉ dài 60 phút.

Kết quả đánh giá lưu trong dự án cho thấy mô hình đạt MAE trung bình 14,12 WTI, thấp hơn khoảng 23,9% so với cách giữ nguyên giá trị hiện tại. Tuy nhiên, lợi thế so với tham chiếu cùng giờ chỉ khoảng 4,0%; tham chiếu này còn tốt hơn về một số chỉ số cảnh báo. Đóng góp rõ nhất của dự án là xây dựng được chuỗi xử lý từ ảnh đến dự báo có thể theo dõi và đánh giá, đồng thời làm rõ những giới hạn của phép đo dựa trên số xe trong ảnh.

1.2 Đầu vào và đầu ra

Đại lượng trung tâm được định nghĩa trực tiếp trong mã nhận diện:

$$WTI = 4 \times \text{car} + 1 \times \text{motorbike} + 7 \times \text{bus} + 6 \times \text{truck}$$

Bảng 1: Đầu vào và đầu ra của hệ thống

Cấp xử lý	**Đầu vào**	**Đầu ra**
Thu ảnh	Snapshot camera từ nguồn giao thông công cộng TP.HCM, tải bằng HTTP	Ảnh màu BGR được OpenCV giải mã
Nhận diện	Ảnh và trọng số `yolo26x.pt`	Khung nhận diện; số lượng người, ô tô, xe máy, xe buýt, xe tải
Xây dựng dữ liệu	Timestamp, số xe và WTI trên từng ảnh	CSV gồm 9 cột; dữ liệu tổng hợp theo phút
Dự báo học máy	61 đặc trưng từ phút hiện tại và tối đa 60 phút quá khứ	60 giá trị WTI tương ứng $t+1$ đến $t+60$
Cảnh báo	Đường dự báo được làm mượt và ngưỡng 100 WTI	ETA đến đầu cửa sổ vượt ngưỡng; trạng thái cảnh báo và chất lượng dữ liệu
Vận hành	Quan sát thật, tham chiếu và dự báo	Dashboard PyQt5, nhật ký mẫu và dự báo trong SQLite

Trong đó, *total* là tổng bốn loại xe; *person* không tham gia *total* hoặc *WTI*. WTI là điểm số có trọng số trên một ảnh. Đơn vị này không tương đương xe/phút, xe/km hay xác suất ùn tắc. Các trọng số là quy ước của dự án; thư mục chưa cung cấp một thực nghiệm hiệu chuẩn chúng với mức chiếm dụng đường hoặc mức chậm trễ giao thông.

Gọi $y(t)$ là WTI_mean tại phút hoàn tất t, mô hình học ánh xạ từ $X(t)$ sang vector $[y(t+1),\ldots,y(t+60)]$. ETA được suy ra từ vector dự báo; mã hiện tại không huấn luyện một bộ hồi quy ETA riêng.

1.3 Từ đề xuất ban đầu đến hệ thống hiện tại

Tài liệu Word là báo cáo đề xuất, trong đó có các phương án và công việc dự kiến. Đối chiếu với mã nguồn cho thấy những thay đổi sau:

Bảng 2: Đối chiếu đề xuất ban đầu và hệ thống hiện tại

Nội dung	**Đề xuất ban đầu**	**Triển khai được kiểm tra**
Nhận diện	Các biến thể YOLO nano được nhắc ở nhiều phần	YOLO("`yolo26x.pt`"), kết hợp chia lát ảnh bằng Supervision
Mô hình chuỗi thời gian	Prophet/STL, XGBoost/LightGBM; cân nhắc LSTM/GRU	MultiOutputRegressor bao ngoài HistGradientBoostingRegressor
Mục tiêu học	Số phút đến khi vượt ngưỡng, có đề cập nhãn bị chặn trên	WTI trực tiếp ở 60 thời điểm tương lai; ETA tính bằng quy tắc
Ngưỡng	Phân vị 85–90 theo lịch sử cùng giờ	Ngưỡng cố định 100 WTI, chưa hiệu chuẩn bằng nhãn giao thông
Triển khai	GitHub Actions và trang web/notebook	Ứng dụng desktop PyQt5; train chạy riêng; lưu vận hành bằng SQLite
Chất lượng ảnh	Dự kiến lọc tối, mờ và mưa	Có xử lý ảnh tải lỗi, loại ảnh lặp hoàn toàn; chưa thấy bộ lọc chất lượng ảnh tương ứng

2 Bộ dữ liệu và phương pháp thu thập

2.1 Nguồn và quy trình thu thập

`core/Get_frame.py` gửi yêu cầu đến đường dẫn `render/ImageHandler.ashx` của nguồn camera giao thông TP.HCM. Yêu cầu chứa định danh camera và tham số thời gian, kèm User-Agent, Referer, thời gian chờ 10 giây. Dữ liệu trả về được chuyển thành mảng NumPy và giải mã bằng `cv2.imdecode()`.

`get_data.py` thực hiện quy trình sau:

1. Lấy ảnh từ camera được chọn, mặc định là Camera 1.
2. Ghi nhận thời gian máy nhận ảnh trước khi chạy nhận diện.
3. So sánh `frame.tobytes()` với ảnh ngay trước đó. Nếu giống hoàn toàn, không tạo thêm mẫu nhận diện.
4. Chạy YOLO trên ảnh mới, đếm phương tiện và tính WTI.
5. Ghi kết quả thành CSV theo lô mỗi 5 mẫu; ghi phần còn lại trong khối `finally` khi thoát bình thường hoặc có ngoại lệ đi qua khối này.

Collector mặc định chạy tối đa 86.400 giây, tương đương 24 giờ. Tên đầu ra đã tồn tại bị từ chối nhằm giữ nguyên đợt thu trước. Dữ liệu thực tế có khoảng cách mẫu trung vị 12 giây; đây là nhịp quan sát đo được, không phải bảo đảm rằng camera nguồn phát ảnh mới chính xác mỗi 12 giây.

Việc so sánh bytes chỉ phát hiện ảnh lặp hoàn toàn liên tiếp. Nó không xác minh độ mới của ảnh phía camera, không nhận biết mọi trường hợp ảnh gần giống và không thay thế được kiểm tra chất lượng nhận diện. Timestamp trong CSV không có thông tin múi giờ; hệ thống xử lý chúng theo quy ước giờ địa phương Việt Nam. Do CSV cũ không lưu phiên bản collector, không thể khẳng định mọi dòng lịch sử đều được tạo bằng chính phiên bản mã hiện tại.

2.2 Quy mô và cấu trúc

Hai CSV chứa tổng cộng 14.109 bản ghi và 9 cột, tương ứng hai đợt quan sát gần 24 giờ, cách nhau khoảng một tuần. Trong thiết kế huấn luyện, `data1` dùng cho fit/validation và refit; `data2` dùng để đánh giá sau khi chọn cách biểu diễn mục tiêu.

Bảng 3: Thuộc tính của hai tập dữ liệu

Thuộc tính	**data1**	**data2**
Số bản ghi gốc	7.044	7.065
Bắt đầu CSV	21/09/2026 17:41:40	28/09/2026 22:39:52
Kết thúc CSV	22/09/2026 17:41:32	29/09/2026 22:39:43
Số mốc phút sau loại hai biên không đầy đủ	1.439	1.439
Phút hoàn toàn không có mẫu	2	3
Phút chỉ có 1–2 mẫu	4	6
Khoảng cách mẫu trung vị	12 giây	12 giây
Khoảng cách mẫu lớn nhất	147 giây	170 giây
Cửa sổ đủ lịch sử và đủ 60 mục tiêu	1.098	956

Một "cửa sổ" hay forecast origin là thời điểm phát dự báo có đủ đầu vào và đầu ra tương lai để đánh giá. Các cửa sổ liên tiếp dùng chung phần lớn lịch sử và mục tiêu; 956 origin không tương đương 956 tình huống giao thông độc lập.

Bảng 4: Ý nghĩa các cột trong tập dữ liệu

Cột CSV	**Ý nghĩa và vai trò**
`timestamp`	Thời điểm bản ghi, định dạng YYYY-MM-DD HH:MM:SS
`person`	Số đối tượng người; không dùng làm đặc trưng dự báo hiện tại
`car, motorbike, bus, truck`	Số phát hiện của bốn loại phương tiện trong ảnh
`total`	Tổng số phát hiện của bốn loại xe
`WTI`	Điểm trọng số phương tiện; cơ sở tạo target theo phút
`WTI_norm`	WTI nhân hệ số logarit theo tổng số xe; không dùng trong model hiện tại

2.3 Phân bố quan sát

Các thống kê dưới đây được tính lại trực tiếp từ từng dòng CSV, trước khi tổng hợp theo phút. Độ lệch chuẩn trong bảng là độ lệch chuẩn mẫu.

Bảng 5: Thống kê phân bố quan sát

Thống kê	**data1**	**data2**
Số xe trung bình/ảnh	22,37	22,95
Trung vị số xe/ảnh	23	24
Khoảng tứ phân vị số xe/ảnh	7–36	11–34
Số xe lớn nhất/ảnh	59	59
WTI trung bình	75,08	73,49
Độ lệch chuẩn WTI	49,57	44,37
Trung vị WTI	77	74
Khoảng tứ phân vị WTI	30–114	34–109
WTI nhỏ nhất–lớn nhất	0–267	0–217
Bản ghi có total = 0	267	86
Tỷ lệ ảnh có WTI > 100	35,18%	31,82%

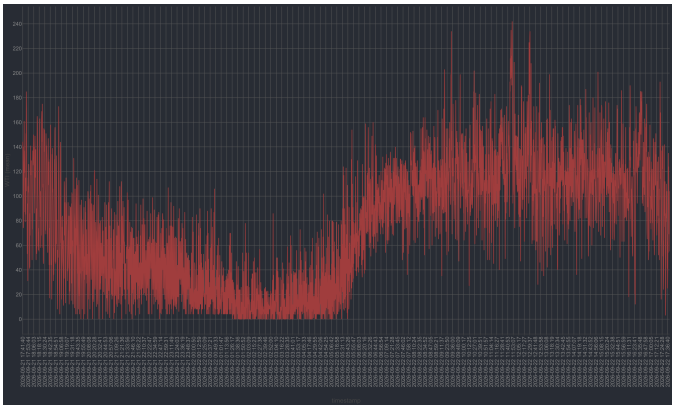
Tỷ lệ vượt 100 ở đây là tỷ lệ ảnh, không phải tỷ lệ phút vượt ngưỡng hay tỷ lệ cửa sổ thỏa quy tắc cảnh báo 3/5. Tương tự, bản ghi không có xe có thể phản ánh cảnh vắng hoặc detector không tìm thấy phương tiện; dữ liệu hiện có chưa đủ để phân biệt hai nguyên nhân cho từng ảnh.

Bảng 6: Tỷ trọng các loại phương tiện

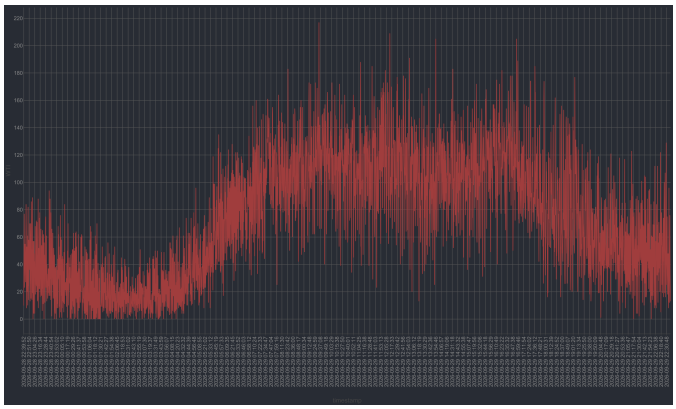
Loại xe	**Tỷ trọng lượt phát hiện (data1)**	**Tỷ trọng lượt phát hiện (data2)**
Ô tô	52,60%	49,61%
Xe máy	32,73%	36,89%
Xe buýt	4,47%	3,86%
Xe tải	10,19%	9,64%

Tỷ trọng được tính bằng tổng số phát hiện của từng loại chia tổng phát hiện phương tiện trên các ảnh. Một xe có thể xuất hiện nhiều lần, vì vậy bảng không thể dùng để suy ra số xe duy nhất đi qua giao lộ. Phân bố cũng chịu ảnh hưởng của góc camera, che khuất và khả năng nhận diện từng lớp.

Hai đợt đều có WTI trung bình thấp vào khoảng 02 giờ. Tính trên chuỗi phút hoàn tất, giờ có WTI trung bình cao nhất là 11 giờ ở `data1` và 16 giờ ở `data2`. Điều này cho thấy vị trí đỉnh và hình dạng chuỗi có thay đổi giữa các đợt; không nên coi một ngày tham chiếu là quy luật cố định. Đỉnh WTI cũng không nhất thiết trùng đỉnh tổng số xe vì thành phần phương tiện có trọng số khác nhau.

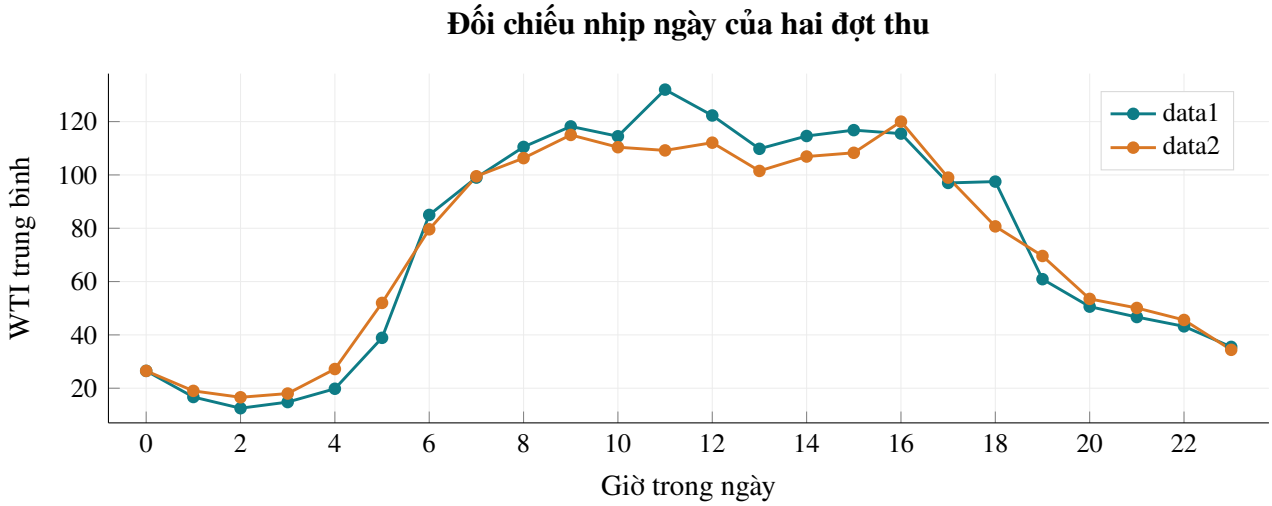


(a) Biểu đồ WTI quan sát của đợt 21–22/09 (`data/chart1.png`). Vùng đêm có mức thấp, sau đó WTI tăng rõ khi chuyển sang buổi sáng.



(b) Biểu đồ WTI quan sát của đợt 28–29/09 (`data/chart2.png`). Hai hình là biểu đồ dữ liệu đã thu, không phải kết quả dự báo.

Hình 2: Đối chiếu biểu đồ WTI quan sát thực tế giữa hai đợt thu thập dữ liệu.



Hình 3: Đối chiếu biến thiên chỉ số WTI trung bình theo các khung giờ trong ngày giữa data1 và data2.

2.4 Chất lượng và tính đại diện

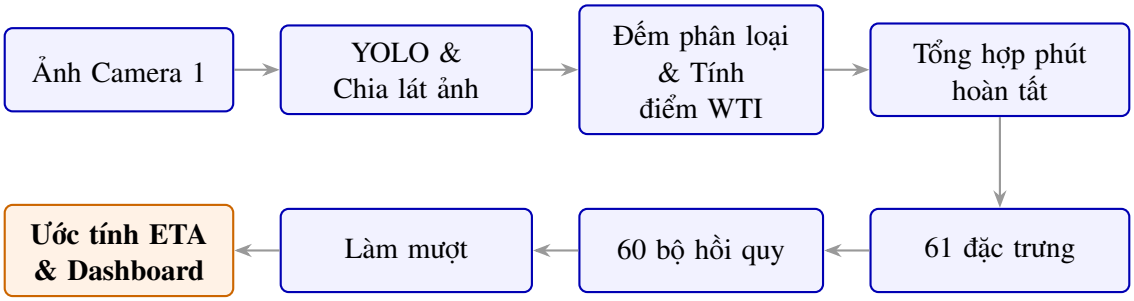
Kiểm tra trực tiếp cho thấy hai CSV không có ô trống hoặc timestamp trùng. Hàm kiểm tra của dự án chấp nhận toàn bộ bản ghi về số đếm nguyên không âm, giá trị hữu hạn và tính nhất quán của `total`, WTI. Mã băm SHA-256 của hai CSV hiện tại khớp thông tin dữ liệu trong báo cáo huấn luyện đã lưu.

Tuy vậy, dữ liệu sạch ở cấp dòng vẫn có thể thiếu theo thời gian: 5 phút hoàn toàn vắng mẫu chỉ xuất hiện rõ sau khi đưa dữ liệu về lưới một phút. Ngoài ra, dữ liệu chưa có `camera_id`, phiên bản detector, ROI, nhãn thời tiết, tốc độ hoặc nhãn ùn tắc. Hai đợt gần 24 giờ chưa đủ để đánh giá mùa vụ tuần, ngày lễ, sự cố hay khả năng chuyển sang giao lộ khác.

3 Quy trình xử lý hệ thống

3.1 Luồng xử lý tổng thể

Luồng xử lý dữ liệu được thiết kế khép kín và tự động hóa qua các công đoạn:



Hình 4: Sơ đồ luồng xử lý dữ liệu và suy luận dự báo tổng thể của hệ thống.

Song song với luồng xử lý trên, hệ thống lưu quan sát và dự báo đã phát ra vào cơ sở dữ liệu SQLite. Khi dữ liệu tương lai đã đến, script đánh giá có thể đối chiếu dự báo với quan sát đúng thời điểm.

Bảng 7: Các thành phần chính và trách nhiệm trong hệ thống

Thành phần	**Trách nhiệm chính**
`core/Get_frame.py`	Tải và giải mã ảnh từ camera giao thông.
`core/Yolo_detect.py`	Nhận diện, đếm số lượng phương tiện theo từng lớp và tính WTI.
`core/vision_worker.py`	Thu ảnh và chạy nhận diện ngoài luồng giao diện người dùng (background thread).
`core/traffic_features.py`	Kiểm tra tính hợp lệ của mẫu, tổng hợp theo phút, tạo đặc trưng và ma trận mục tiêu.
`training_model.Py`	Lựa chọn target mode, huấn luyện (fit), đánh giá và lưu trữ model bundle.
`core/traffic_forecast.py`	Kiểm tra bundle, suy luận dự báo, chạy nhánh dự báo tạm thời và tính ETA.
`core/forecast_worker.py`	Quản lý lịch sử chuỗi thời gian, hoàn tất phút và cập nhật dữ liệu dự báo.
`core/traffic_store.py`	Lưu trữ và khôi phục mẫu quan sát, các phiên bản dự báo bằng SQLite.
`ui/traffic_forecast_chart.py`	Trực quan hóa chuỗi lịch sử, đường dự báo, đường tham chiếu và ngưỡng cảnh báo.

3.2 Nhận diện phương tiện và tạo phép đo

Hệ thống sử dụng mô hình nhận diện đối tượng `yolo26x.pt` thông qua thư viện Ultralytics. Để tăng cường khả năng phát hiện phương tiện ở xa và bị che khuất trong khung nhìn rộng của camera, mô-đun tích hợp `supervision.InferenceSlicer` nhằm chia ảnh thành các lát nhỏ kích thước 256×256 pixel, thực hiện nhận diện độc lập trên từng lát rồi ghép hợp nhất kết quả. Các class ID COCO được theo dõi gồm: 0 (người), 2 (ô tô), 3 (xe máy), 5 (xe buýt) và 7 (xe tải).

Chia lát ảnh là một lựa chọn kỹ thuật phù hợp với cảnh camera góc rộng có mật độ phương tiện cao: mỗi lần suy luận chỉ cần xử lý một vùng không gian hẹp với độ phân giải chi tiết. Tuy nhiên, đây là giải thích kỹ thuật về vai trò của kiến trúc, chưa phải kết quả định lượng rằng kỹ thuật chia lát đã cải thiện độ chính xác (Precision/Recall). Dự án hiện tại chưa xây dựng tập ảnh gán nhãn cục bộ kèm phép so sánh có kiểm soát để đo đạc mức độ cải thiện này.



Hình 5: Ảnh thử nghiệm đầu vào `test_img/1.png`, ghi nhận các phương tiện ở nhiều khoảng cách và kích thước khác nhau.

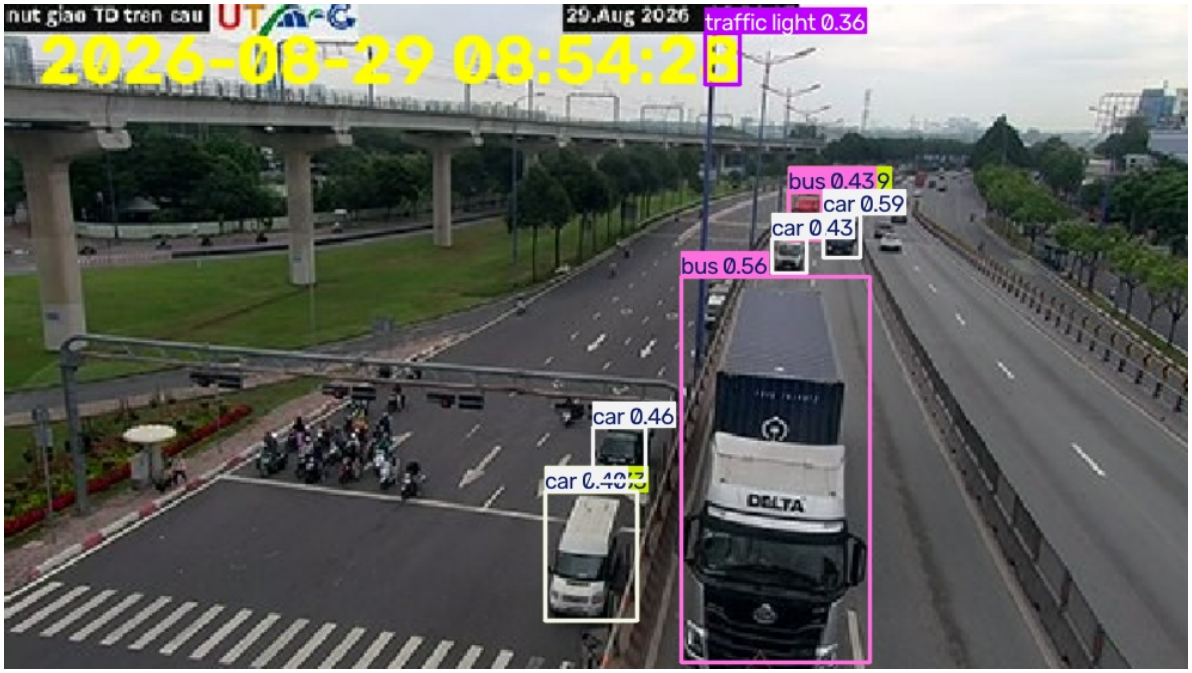
Một script thử nghiệm độc lập, `test_yolo.py`, khảo sát kích thước lát cắt `slice_wh=(512, 512)` và lưu tại `runs/supervision_test9.png`. Do đó, không đồng nhất kích thước 512×512 trong script thử nghiệm với cấu hình lát 256×256 của luồng vận hành chính thức.

3.3 Kiểm tra và tiền xử lý chuỗi thời gian

Kiểm tra schema: Pipeline yêu cầu dữ liệu phải có cột `timestamp` cùng bốn cột đếm phương tiện, `total` và `WTI`. `timestamp` phải hợp lệ, đơn điệu tăng và không trùng lặp; số lượng phương tiện đếm được phải là các số nguyên hữu hạn không âm. Hàm kiểm tra sẽ tính toán lại tổng số xe và chỉ số WTI để phát hiện dữ liệu sai lệch công thức trước khi đưa vào sắp xếp theo thời gian.

Tổng hợp theo phút: Mỗi khoảng thời gian $[10:00, 10:01)$ được gán mốc nhãn $10:01$, tức thời điểm phút đó đã hoàn tất. Quy ước này giúp ngăn chặn việc sử dụng một phút đang thu thập dở dang như thể đã biết đầy đủ thông tin. Tại mỗi phút hoàn tất, hệ thống tính toán: giá trị trung bình số xe từng loại, trung bình WTI/total, độ lệch chuẩn, giá trị cực đại và số lượng mẫu thu được. Độ lệch chuẩn nội phút sử dụng bậc tự do $\text{ddof} = 0$; những phút chỉ có một mẫu quan sát sẽ có độ lệch chuẩn bằng 0.

Xử lý giá trị thiếu: Những phút hoàn toàn không thu được mẫu nào được gán giá trị `NaN` ở các phép đo và số mẫu bằng 0. Pipeline tuyệt đối không tự ý điền giá trị 0 hoặc nội suy để tránh biến khoảng thời gian mất tín hiệu camera thành quan sát giao thông thông thoáng. Hai đầu biên của file CSV không đủ phút sẽ bị loại bỏ.



Hình 6: Kết quả thử nghiệm lưu tại `runs/detect/predict/1.jpg`. Ảnh hiển thị bounding box, nhãn lớp và độ tin cậy nhận diện.

Mọi cửa sổ thời gian bị thiếu lịch sử hoặc thiếu bất kỳ giá trị mục tiêu nào trong 60 phút tiếp theo đều bị loại khỏi tập học có giám sát (supervised dataset).

Chuẩn hóa: Luồng dự báo không áp dụng các phép biến đổi như `StandardScaler`, `MinMaxScaler` hoặc đưa WTI về đoạn $[0,1]$. Cột `WTI_norm` được lưu trong dữ liệu thô theo công thức:

$$\text{WTI_norm} = \text{WTI} \times [1 + \ln(1 + \text{total})]$$

Mặc dù tên cột chứa tiếp vĩ ngữ "norm", công thức này thực chất khuếch đại WTI theo tổng số xe chứ không đưa dữ liệu về khoảng chuẩn. Cả tập đặc trưng lẫn mục tiêu của mô hình hiện tại đều không sử dụng cột này. Việc giữ nguyên WTI ở thang đo gốc giúp sai số MAE và ngưỡng cảnh báo có cùng đơn vị trực quan, dễ đối chiếu.

Chất lượng đầu vào lúc vận hành: Nhánh mô hình yêu cầu chuỗi 61 phút dữ liệu thực tế liên tục, trong đó mỗi phút phải có ít nhất 3 mẫu hợp lệ. Khi thiếu lịch sử hoặc xuất hiện phút thưa mẫu, hệ thống tự động chuyển sang cơ chế ước lượng tạm thời (nếu có dữ liệu tham chiếu). Khi phút mới nhất hoàn toàn không có mẫu quan sát, hệ thống lập tức dừng đưa ra dự báo.

Lưu ý kỹ thuật: Hàm `supervised_data()` trong quá trình huấn luyện và kiểm thử offline chỉ yêu cầu dữ liệu không bị thiếu (`non-null`), chưa áp dụng đồng loạt điều kiện tối thiểu 3 mẫu/phút như nhánh vận hành thực tế. Vì vậy, tập 956 origin đánh giá offline không đồng nhất hoàn toàn với tập thời điểm mà hệ thống chấp nhận kích hoạt mô hình ngoài thực tế.

3.4 Thiết kế 61 đặc trưng

Từ chuỗi dữ liệu lịch sử một giờ, hệ thống trích xuất tổng cộng 61 đặc trưng đầu vào cho mô hình:

Với chuỗi tín hiệu s, độ dốc trong mã nguồn được tính bằng công thức hiệu số đơn giản:

$$\text{slope}_w(t) = \frac{s(t) - s(t-w)}{w}$$

Đây không phải là hệ số góc thu được từ phép hồi quy tuyến tính trên toàn bộ cửa sổ w.

Bảng 8: Bảng thiết kế 61 đặc trưng đầu vào

Nhóm đặc trưng	**Số lượng**	**Nội dung chi tiết**	**Thông tin cung cấp**
Phút hiện tại	11	Trung bình 4 loại xe; mean, std, max của `total` và `WTI`; số mẫu	Mức độ hiện diện, cơ cấu thành phần dòng xe, dao động nội phút và độ phủ dữ liệu.
Giá trị trễ (Lags)	16	Lag 1, 2, 3, 5, 10, 15, 30, 60 cho cả `total` và `WTI`	Nắm bắt trạng thái giao thông gần nhất và mức nền tại các mốc xa hơn trong quá khứ.
Thống kê trượt	26	Mean (5, 15, 30, 60); std, min, max (5, 15, 30) cho cả `total` và `WTI`	Xu hướng trung tâm, biên độ biến thiên và mức độ bất ổn định cục bộ.
Độ dốc (Slope)	6	Slope 5, 15, 30 cho `total` và `WTI`	Hướng tăng/giảm và tốc độ biến thiên trung bình của lưu lượng.
Thời gian chu kỳ	2	`hour_sin`, `hour_cos`	Vị trí của thời điểm quan sát trong chu kỳ 24 giờ.
Tổng cộng	**61**		

Mã hóa thời gian theo chu kỳ sử dụng hàm sin và cos:

$$\text{hour_sin} = \sin\left(\frac{2\pi \times \text{giờ}}{24}\right), \quad \text{hour_cos} = \cos\left(\frac{2\pi \times \text{giờ}}{24}\right)$$

trong đó giờ là số thực bao gồm cả phần lẻ thập phân tính theo phút. Cách biểu diễn này đảm bảo tính liên tục hình học giữa hai thời điểm ranh giới 23:59 và 00:00.

Việc khai thác song song cả `total` và `WTI` giúp mô hình nắm bắt đồng thời cả mật độ lượng xe lẫn cơ cấu trọng số: hai khung hình có cùng tổng số xe vẫn cho WTI khác biệt rõ rệt khi tỷ lệ xe buýt hoặc xe tải thay đổi. Hàm `create_features()` chỉ trích xuất từ dữ liệu hiện tại và quá khứ; hàm `create_targets()` dịch chuyển WTI về 60 bước tương lai để tạo nhãn. Cùng một mô-đun được sử dụng đồng bộ cho cả pha huấn luyện lẫn suy luận nhằm loại bỏ rủi ro sai lệch thứ tự cột.

3.5 Kiến trúc dự báo và hậu xử lý

Hệ thống sử dụng kiến trúc `MultiOutputRegressor(HistGradientBoostingRegressor)` gồm 60 bộ hồi quy riêng biệt, mỗi bộ phụ trách dự báo cho một bước thời gian (horizon) từ $t+1$ đến $t+60$. Tại thời điểm t, tất cả 60 mô hình đều nhận chung vector đầu vào $X(t)$; dự báo tại $t+2$ hoàn toàn không phụ thuộc vào kết quả của $t+1$.

Thiết kế dự báo trực tiếp (Direct Multi-step) giúp triệt tiêu hoàn toàn hiện tượng tích lũy và khuếch đại sai số qua các bước đệ quy. Ngược lại, do 60 bộ hồi quy học hoàn toàn độc lập, chúng không tự bảo đảm tính liên tục mượt mà của đường cong dự báo theo trục thời gian, đồng thời làm tăng chi phí lưu trữ và suy luận.

Sau suy luận, chuỗi dự báo được xử lý qua các bước:

1. Chặn dưới giá trị tại 0 ($\max(0, \hat{y})$).
2. Làm mượt bằng bộ lọc trung bình trượt 3 điểm (Moving Average 3), nối liền với tối đa hai điểm WTI quan sát thực tế gần nhất.
3. Xác định ETA: Áp dụng quy tắc tìm cửa sổ 5 phút liên tiếp có ít nhất 3 điểm vượt ngưỡng 100 WTI (quy tắc 3/5). Giá trị ETA trỏ đến mốc bắt đầu của cửa sổ đầu tiên thỏa mãn điều kiện.

Bảng 9: Các trạng thái hoạt động của hệ thống

Trạng thái	Ý nghĩa trong hệ thống
NORMAL	Nhánh mô hình không phát hiện cửa sổ vượt ngưỡng nào trong 60 phút tới.
PROVISIONAL	Đang hoạt động ở chế độ ước lượng tạm thời và chưa phát hiện nguy cơ vượt ngưỡng.
WATCH	Phát hiện cửa sổ dự báo vượt ngưỡng, thời điểm bắt đầu xảy ra sau hơn 5 phút.
WARNING	Cửa sổ vượt ngưỡng bắt đầu trong vòng 5 phút tới, hoặc quan sát thực tế đã vượt ổn định.
INSUFFICIENT_DATA	Dữ liệu đầu vào chưa đáp ứng đủ tiêu chuẩn để phát tín hiệu dự báo.
MODEL_ERROR	Xảy ra lỗi trong quá trình suy luận hoặc lỗi cấu trúc dữ liệu bundle.

3.6 Khởi động và dự báo tạm thời

Để giải quyết bài toán khởi động lạnh (Cold-start) khi ứng dụng vừa bật và chưa tích lũy đủ 61 phút quan sát, hệ thống xây dựng một đường tham chiếu gồm 96 ô thời gian (mỗi ô 15 phút) tính từ trung bình của tập `data1`.

Hàm `provisional_values()` sử dụng tối đa 30 phút thực tế gần nhất để điều chỉnh đường tham chiếu:

- Chênh lệch mức nền giữa thực tế và tham chiếu được dùng để bù trừ mức độ cao/thấp.
- Khi có tối thiểu 10 phút dữ liệu thật, hệ thống ước lượng xu hướng biến thiên và chặn hệ số góc trong đoạn $[-1, 1]$ WTI/phút.
- Mức độ hiệu chỉnh suy giảm dần theo thời gian qua trọng số hàm mũ $\exp(-h/20)$, và giới hạn độ dốc qua $10 \times [1 - \exp(-h/10)]$, giúp các sai lệch ngắn hạn không bị kéo dài suốt cả giờ.

Các quan sát tham chiếu được đánh dấu cờ `is_reference` và không bao giờ được đưa vào mô hình học máy như dữ liệu thực. Khoảng dữ liệu bị mất trong phiên cũng không bị điền lấp bằng tham chiếu, đảm bảo tính trung thực của phép đo giao thông.

4 Lựa chọn mô hình và tinh chỉnh siêu tham số

4.1 Cơ sở lựa chọn

4.1.1 Cơ sở lựa chọn kiến trúc thuật toán (Model Selection)

Trong bài toán dự báo lưu lượng và tốc độ giao thông đa bước thời gian, mô hình được lựa chọn là HistGradientBoostingRegressor (HGB) được bao bọc bởi kiến trúc MultiOutputRegressor. Sự phối hợp này được thiết lập dựa trên các căn cứ lý thuyết và thực nghiệm sau:

- **Xử lý mối quan hệ phi tuyến tính phức tạp (Non-linear Correlations):** Dữ liệu giao thông đô thị mang tính chất phi tuyến rõ rệt, bị tác động bởi chu kỳ thời gian, hiệu ứng dòng chảy không gian và các biến cố ngẫu nhiên. HGB — một biến thể ưu việt của thuật toán Gradient Boosted Decision Trees (GBDT) dựa trên phân thùng dữ liệu (binning) — có khả năng xấp xỉ tốt các hàm phi tuyến đa chiều mà không đòi hỏi các giả định nghiêm ngặt về phân phối chuẩn của dữ liệu đầu vào.
- **Kiểm soát độ phức tạp không gian (Spatial Complexity Control):** Thay vì xây dựng một mô hình ma trận giao thông toàn cục có độ phức tạp tính toán tăng theo cấp số nhân, phương pháp tiếp cận hiện tại áp dụng kiến trúc MultiOutputRegressor. Chiến lược này tách biệt việc dự báo chuỗi thời gian nhiều bước (multi-step forecast horizon) thành các bài toán quy nạp song song độc lập cho từng vị trí/cảm biến. Cách tiếp cận này giúp cô lập rủi ro lan truyền lỗi (error propagation) giữa các khu vực không gian khác nhau, đồng thời duy trì chi phí tính toán ở mức tuyến tính đối với số lượng điểm đo.

4.1.2 Chiến lược thiết lập không gian siêu tham số (Hyper-parameter Configuration)

Chiến lược tối ưu hóa mô hình trong dự án tuân theo các nguyên tắc quản trị thực nghiệm nghiêm ngặt:

- **Cấu hình tĩnh thay vì Tìm kiếm tự động (Static Configuration vs. Hyper-parameter Search):** Các siêu tham số của mô hình HGB không được khởi tạo thông qua các kỹ thuật quét tự động toàn cục như Grid Search, Random Search hay Bayesian Optimization. Thay vào đó, bộ tham số được ấn định tĩnh dựa trên tri thức chuyên ngành (domain expertise) về bản chất chuỗi thời gian giao thông và các thử nghiệm kiểm chứng cục bộ nhằm tránh hiện tượng quá khớp (overfitting) trên tập kiểm thử.
- **Tập trung xác minh dạng biểu diễn mục tiêu (Target Representation Validation):** Quá trình thực nghiệm tập trung phần lớn năng lực kiểm chứng vào việc lựa chọn dạng biểu diễn của chuỗi giá trị đầu ra:
  - *Biểu diễn Tuyệt đối (Absolute Target):* Dự báo trực tiếp giá trị thực tế của biến giao thông tại thời điểm $t+k$.
  - *Biểu diễn Sai biệt (Delta Target):* Dự báo mức độ biến động $\Delta = Y_{t+k} - Y_t$.

  $\Rightarrow$ **Kết quả thực nghiệm:** Dạng biểu diễn Absolute Target mang lại độ ổn định cao hơn đáng kể. Biểu diễn Delta tỏ ra nhạy cảm quá mức với nhiễu tần số cao tại thời điểm gốc t, dẫn đến hiện tượng tích lũy sai số lớn khi dự báo xa.

4.2 Phần thực sự được lựa chọn bằng validation

Script thử hai cách đặt mục tiêu, sử dụng cùng cấu hình HGB:

Bảng 10: So sánh dạng biểu diễn mục tiêu trên tập validation của data1

Cách biểu diễn	Mục tiêu học	MAE validation sau làm mượt
Absolute	$WTI(t+h)$	20,42 WTI
Delta	$WTI(t+h) - WTI(t)$	23,79 WTI

Với delta, giá trị hiện tại được cộng trở lại khi suy luận. Trên validation của data1, absolute có MAE thấp hơn nên được chọn. Lựa chọn này chỉ được chứng minh trong cách chia dữ liệu và cấu hình đã thử; không phải kết luận rằng dự báo delta luôn kém hơn.

Không có `GridSearchCV`, `RandomizedSearchCV` hoặc nhật ký tìm kiếm lưới siêu tham số trong luồng train được kiểm tra. Tham số `-max-iter` cho phép người chạy thay đổi số vòng, nhưng sự tồn tại của tùy chọn không chứng minh đã thử nhiều giá trị và chọn tối ưu.

4.3 Cấu hình hiện tại và ý nghĩa của từng tham số

Các giá trị trên là cấu hình cố định được lưu trong mã, chưa phải "bộ siêu tham số tối ưu" có chứng cứ tìm kiếm. Phân tích tác dụng của chúng giải thích lựa chọn kỹ thuật, không thay thế thực nghiệm so sánh các cấu hình.

Horizon 60 phút, lịch sử 61 điểm, làm mượt 3 phút, ngưỡng 100 WTI và quy tắc 3/5 là các tham số của toàn hệ thống. Chúng tác động đến lượng dữ liệu cần có, độ nhạy cảnh báo và độ trễ, nhưng không nên trộn lẫn với siêu tham số cấu trúc cây. Chưa có bằng chứng ngưỡng 100 đã được chọn theo phân vị 85–90 như trong đề xuất ban đầu.

4.4 Chia dữ liệu và ngăn rò rỉ thời gian

Quy trình trong `training_model.Py` gồm:

1. Tạo 1.098 origin hợp lệ từ data1, mỗi origin có 61 đặc trưng và 60 target.

Bảng 11: Cấu hình siêu tham số của mô hình HistGradientBoostingRegressor

Tham số	Giá trị	Vai trò và đánh đổi đối với bài toán
`max_iter`	200	Số vòng boosting tối đa. Tăng có thể giảm sai số fit nhưng tốn thời gian và dễ bám nhiễu trên các cửa sổ có tương quan cao.
`learning_rate`	0,05	Mức đóng góp của mỗi vòng. Bước nhỏ giúp cập nhật từ từ, nhưng phải xét cùng số vòng; ít vòng với bước quá nhỏ có thể chưa học đủ.
`max_leaf_nodes`	15	Giới hạn độ phức tạp mỗi cây. Nhiều lá mô tả tương tác chi tiết hơn nhưng dễ ghi nhớ các trạng thái hiếm của chỉ một ngày thu.
`min_samples_leaf`	25	Yêu cầu đủ mẫu trong lá, hạn chế phân tách dựa trên vài đỉnh nhiễu. Các mẫu chồng lấn vẫn không độc lập, nên 25 mẫu không đồng nghĩa 25 sự kiện khác nhau.
`l2_regularization`	5,0	Hạn chế độ lớn cập nhật ở lá, giúp giảm độ nhạy với nhóm quan sát ít hoặc nhiễu; quá mạnh có thể làm phản ứng với đỉnh thật yếu đi.
`early_stopping`	False	Không dùng cơ chế validation nội bộ tự động; script tự quản lý validation theo thời gian và khoảng loại trừ mục tiêu.
`random_state`	42	Cố định nguồn ngẫu nhiên có liên quan để hỗ trợ tái lập; không phải tham số nhằm trực tiếp tăng độ chính xác.
`n_jobs`	1	Giới hạn chạy song song ở lớp `MultiOutputRegressor`. Cùng `threadpool_limits(1)`, tránh huy động quá nhiều luồng CPU; chưa có benchmark để khẳng định cấu hình này nhanh nhất.

2. Lấy phần cuối của chuỗi làm validation, gồm 220 origin. Sau loại các origin có mục tiêu chạm vùng validation, phần fit còn 818 origin; 60 origin sát ranh giới không dùng ở giai đoạn lựa chọn.

3. Origin fit cuối là 08:20 ngày 22/09; origin validation đầu là 09:21. Target xa nhất của origin fit cuối kết thúc lúc 09:20, trước validation.

4. So sánh absolute và delta bằng MAE trung bình 60 horizon sau làm mượt, chọn absolute.

5. Refit trên toàn bộ 1.098 origin data1 rồi đánh giá 956 origin data2. Hai tập phút train/test cách nhau 8.940 phút.

Thiết kế không xáo trộn ngẫu nhiên và không lấy dữ liệu tương lai làm feature. Khoảng loại trừ đặc biệt cần thiết vì mỗi origin mang theo cả 60 phút nhãn tương lai: chỉ chia theo timestamp của đầu vào mà bỏ qua phần nhãn sẽ tạo rò rỉ qua ranh giới.

Validation hiện chỉ bao phủ một phần ngày. Đồng thời data2 đã được phân tích trong nhiều báo cáo của dự án. Nếu tiếp tục sửa phương pháp dựa trên các kết quả này, cần một đợt thu mới giữ riêng để đánh giá cuối; data2 lúc đó không còn là bằng chứng hoàn toàn độc lập cho lựa chọn mới.

4.5 Kết quả so sánh đã lưu

Bảng 12 lấy từ `models/traffic_wti_forecast.metrics.json`. MAE tính theo đơn vị WTI, đối chiếu dự báo đã làm mượt với WTI trung bình phút chưa làm mượt. Báo cáo này kiểm tra dữ liệu và cách tính trong mã, không huấn luyện lại mô hình để tạo bộ điểm mới.

Bảng 12: So sánh MAE giữa các phương pháp trên tập kiểm thử data2

Phương pháp	MAE +1	MAE +15	MAE +30	MAE +60	MAE TB 60 horizon
HGB, làm mượt 3 phút	13,70	13,40	14,10	14,71	14,12
Tham chiếu cùng giờ từ data1	14,27	14,77	14,88	14,35	14,71
Giữ nguyên WTI hiện tại	15,72	17,04	17,29	20,70	18,55
Ngoại suy slope 15 phút	15,86	28,23	38,55	62,13	40,35

HGB có ưu thế về MAE trung bình, nhưng tại +60 phút, baseline cùng giờ tốt hơn. Ngoại suy tuyến tính có sai số tăng mạnh ở horizon xa: tiếp tục kéo một xu hướng ngắn hạn trong cả giờ là giả định không phù hợp với nhiều đoạn chuỗi đã quan sát.

Bảng 13: Chỉ số phát hiện vượt ngưỡng trên 956 origin của data2

Chỉ số vượt ngưỡng, trên 956 origin	**HGB làm mượt 3 phút**	**Tham chiếu cùng giờ**
Origin có tương lai vượt ngưỡng theo quy tắc	530	530
Cảnh báo đúng	491	500
Báo nhầm	7	0
Bỏ sót	39	30
Precision	98,59%	100,00%
Recall	92,64%	94,34%
F1	0,9553	0,9709
ETA MAE trên origin cảnh báo đúng	7,09 phút	3,95 phút

$F_1 = 0,9553$ không có nghĩa "dự báo kẹt xe chính xác 95,53%". Nhãn ở đây được tạo từ WTI vượt ngưỡng thử nghiệm, đơn vị đánh giá là cửa sổ dự báo chồng lấn, và phép đo chưa có ground truth ùn tắc độc lập.

ETA MAE chỉ tính trên các origin vừa có sự kiện theo WTI vừa được phương pháp cảnh báo. Những ca bỏ sót không tham gia phép tính ETA. Hai cột ETA cũng dùng tập origin cảnh báo đúng khác nhau; không nên diễn giải chênh lệch như một so sánh ghép cặp tuyệt đối. Báo cáo audit đã lưu có kiểm tra trên tập chung 487 origin, ghi nhận ETA MAE khoảng 7,10 phút cho model và 3,85 phút cho tham chiếu.

Thử lấy mỗi 60 origin hợp lệ một lần trong báo cáo model chỉ còn 16 origin, trong đó 9 dương tính. MAE trung bình ở tập thưa này là 14,25 WTI, nhưng kích thước nhỏ chưa cho phép kết luận chắc chắn về độ ổn định trên các đợt giao thông độc lập.

4.6 Tác động của làm mượt và phiên bản kết quả

Bảng 14: Tác động của kỹ thuật làm mượt 3 phút đối với mô hình HGB

Chỉ số của HGB	**Dự báo thô**	**Dự báo làm mượt 3 phút**
MAE trung bình	14,40	14,12
MAE +1 phút	12,52	13,70
Báo nhầm	12	7
Bỏ sót	32	39
ETA MAE trên các ca cảnh báo đúng tương ứng	6,26 phút	7,09 phút

Làm mượt giảm dao động và báo nhầm, nhưng tăng bỏ sót và làm sai số ở phút gần nhất lớn hơn. Chọn một đường cong đẹp hơn trên UI vì thế là quyết định có đánh đổi về chất lượng cảnh báo.

Trong thư mục còn có `traffic_backtest.json`, `warm_start_metrics.json` và báo cáo lịch sử liên quan phiên bản 30 phút. Không sử dụng các kết quả này làm điểm số cho model WTI 60 phút. Các mục `provisional_3/5/15/30/60` trong metrics của model có kết quả giống nhau và được audit mô tả là của cách hiệu chỉnh cũ. Mã `provisional_values()` hiện đã dùng hiệu chỉnh mức/xu hướng giảm dần; chưa có bộ metric mới tương ứng trong các tệp đã kiểm tra để khẳng định chất lượng của thay đổi này.

5 Điểm nổi bật và đóng góp của dự án

5.1 Kết nối thị giác máy tính với dự báo chuỗi thời gian

Dự án không dừng ở hình có bounding box. Số đếm được chuyển thành một chuỗi đo có timestamp, tổng hợp theo phút, dùng cùng định nghĩa đặc trưng khi train và chạy trực tiếp, rồi biến thành đường dự báo và ETA.

Sự liên kết này là đóng góp ứng dụng rõ ràng: mỗi bước có đầu vào và đầu ra có thể kiểm tra, thay vì chỉ trình diễn một mô hình riêng lẻ.

Hình 7: Kết quả lưu từ thử nghiệm Supervision tại `runs/supervision_test9.png`, minh họa nhiều phương tiện nhỏ và che khuất trong cảnh nút giao. Script thử nghiệm sử dụng lát 512×512; ảnh không phải bảng đo precision/recall và không chứng minh ưu thế định lượng so với lát 256×256.

5.2 Phân biệt dữ liệu thật, tham chiếu và dữ liệu mất

Khởi động ứng dụng tạo ra một vấn đề thực tế: model cần 61 điểm phút, nhưng người dùng muốn nhìn thấy thông tin ngay. Dự án giải quyết bằng tham chiếu học từ data1, đánh dấu riêng các phút tham chiếu và dùng một nhánh tạm thời. Khi quan sát thật tích lũy, chúng thay thế tham chiếu; khi đủ điều kiện mới chuyển sang model.

Điểm đáng chú ý là lịch sử tham chiếu không được đưa vào estimator như dữ liệu đo thật, và mất camera sau khởi động không bị che bằng một đường nội suy. Cách xử lý này giữ được ý nghĩa của phép đo và trạng thái chất lượng dữ liệu.

5.3 Giữ danh tính nguồn dự báo khi người dùng đổi camera

Giao diện cho phép chọn camera để xem, nhưng nguồn dự báo luôn là Camera 1. `CameraWorker` phát số đếm từ camera dự báo cố định; `ForecastWorker` loại mẫu có tên camera khác. Nhờ đó thao tác đổi góc xem không làm lịch sử chuỗi thời gian bị trộn giữa hai vị trí.

Tính độc lập về nguồn không đồng nghĩa độc lập về tài nguyên: việc lấy ảnh và nhận diện camera đang xem thêm vẫn nằm trong vòng worker, có thể làm chu kỳ Camera 1 dài hơn. Chưa có số đo latency để định lượng ảnh hưởng.

5.4 Xử lý bất đồng bộ và lưu bằng chứng trước khi biết tương lai

Thu ảnh/YOLO và dự báo được đưa ra khỏi luồng giao diện. Model chỉ tải một lần; biểu đồ tái sử dụng Figure và các đối tượng vẽ khi cập nhật. Đây là lựa chọn nhằm giữ UI đáp ứng mà không cần huấn luyện lại hoặc dựng lại toàn bộ biểu đồ mỗi lần có dữ liệu.

SQLite lưu timestamp quan sát, origin dự báo, thời điểm phát, các giá trị dự báo thô/đã làm mượt, model ID và phương pháp. Script `evaluate_live_forecasts.py` chỉ lấy lần phát đầu tiên của mỗi origin, loại dự báo phát quá muộn và chỉ chấm khi đủ dữ liệu tương lai với độ phủ mẫu yêu cầu. Nhờ vậy việc đánh giá không chọn lại một phiên bản dự báo thuận lợi sau khi đã biết kết quả.

Lịch sử được khôi phục khi ứng dụng mở lại, nhưng khoảng thời gian ứng dụng tắt vẫn là khoảng thiếu. Collector ghi theo lô ngắn cũng giảm nguy cơ mất toàn bộ đợt thu; việc dừng cưỡng bức vẫn có thể làm mất lô chưa ghi cuối cùng.

5.5 Kiểm tra tính tương thích và bảo vệ model đang dùng

Bundle dự báo chứa danh sách và thứ tự đặc trưng, horizon, history window, target mode, đường tham chiếu, metrics và thông tin phiên bản môi trường. `validate_bundle()` kiểm tra cấu trúc quan trọng trước khi suy luận, bao gồm đủ 60 estimator và đúng thứ tự cột.

Huấn luyện mới không tự ghi đè artifact đang tồn tại: script chuyển sang tên candidate, lưu model rồi tải lại để so sánh một dự báo với kết quả trước khi lưu. Thiết kế này tạo cơ sở cho việc kiểm tra ứng viên trước khi thay model đang vận hành. Tuy nhiên, script chưa có cổng tự động từ chối triển khai theo toàn bộ tiêu chí cảnh báo; việc lưu thành công không chứng minh model mới tốt hơn.

5.6 Kiểm thử hướng vào lỗi có ý nghĩa

Các tệp test hiện có bao phủ những tình huống như feature không sử dụng tương lai, đúng thứ tự lag 60, lệch schema, thiếu model, timestamp dự báo, quy tắc 3/5, mất mẫu, phút thưa, đổi camera, khôi phục SQLite, giữ phiên bản forecast và ghi CSV khi có lỗi nhận diện.

Báo cáo này đọc các kiểm thử để xác định ý đồ và phạm vi bảo vệ của hệ thống, không báo chúng là một lượt test mới đã chạy. Kiểm thử logic hoặc ảnh UI chỉ xác nhận từng phần hành vi; độ chính xác giao thông trực tiếp vẫn cần quan sát tương lai có nhãn và nhật ký tương ứng.

Những điểm nổi bật trên là đóng góp kỹ thuật trong phạm vi dự án. Tài liệu chưa đưa ra bằng chứng về một thuật toán học máy mới hoặc so sánh học thuật để khẳng định tính mới ở cấp nghiên cứu phương pháp.

6 Bài học kinh nghiệm

6.1 Định nghĩa đúng đại lượng trước khi tối ưu mô hình

WTI tiện cho việc tạo dữ liệu có cấu trúc, nhưng nó là một phép đo thay thế. Nhiều xe trong ảnh có thể vẫn đang di chuyển tốt; một hàng xe ít hơn có thể đang đứng yên. Chỉ tối ưu dự báo WTI không tự giải quyết được khoảng cách giữa "đông xe trong khung hình" và "ùn tắc gây chậm trễ".

Bước phát triển tiếp theo nên bắt đầu từ nhãn giao thông độc lập và tiêu chí quan sát rõ ràng, như trạng thái dòng xe hoặc hàng chờ trong một vùng quan tâm. Khi đó mới có cơ sở hiệu chuẩn trọng số, ngưỡng và đánh giá giá trị của cảnh báo. Đây là hướng cải thiện từ giới hạn đã phát hiện, chưa phải chức năng hiện có.

6.2 Không có ô trống không có nghĩa chuỗi liên tục

Cả hai CSV đều đầy đủ giá trị trên mỗi dòng, nhưng có 5 phút hoàn toàn mất mẫu. Nếu chỉ kiểm tra `isna()` trên bảng gốc, hệ thống sẽ bỏ qua những khoảng chưa từng được ghi. Chuẩn hóa trục thời gian, giữ NaN và đo số mẫu mỗi phút là cần thiết trước khi tạo lag hoặc kết luận camera đang hoạt động ổn định.

Chính sách chất lượng cũng cần thống nhất giữa train, backtest và vận hành. Hiện nhánh live yêu cầu tối thiểu 3 mẫu/phút trong lịch sử, còn tập supervised chỉ loại phần thiếu. Đồng bộ tiêu chí này sẽ giúp phép đánh giá phản ánh đúng các thời điểm model thực sự được phép dự báo.

6.3 Baseline phải phù hợp với cấu trúc dữ liệu

Giữ nguyên giá trị hiện tại là một đối chứng dễ hiểu, nhưng chưa đủ khi chuỗi có biến động theo giờ. Baseline cùng giờ từ data1 đạt MAE rất gần HGB và tốt hơn ở F1 cùng ETA trong lần đánh giá đã lưu. Vì vậy "thắng persistence" chưa đủ để khẳng định phần học máy mang lại lợi ích rõ rệt cho mục tiêu cảnh báo sớm.

Các lần đánh giá sau nên tiếp tục giữ baseline theo giờ, đồng thời kiểm tra trên nhiều đợt mới. Chưa nên biến kết quả một capture thành kết luận HGB hoặc baseline sẽ luôn vượt trội.

6.4 Đường dự báo đẹp và cảnh báo hữu ích là hai mục tiêu khác nhau

Làm mượt giảm MAE trung bình và báo nhầm, nhưng tăng bỏ sót từ 32 lên 39 origin. Điều này cho thấy tham số hiển thị có thể thay đổi hành vi cảnh báo. Khi thiết kế tiếp, cần xác định trước chi phí bỏ sót, mức báo nhầm chấp nhận được và thời gian cảnh báo hữu ích; không chỉ chọn cấu hình theo một MAE trung bình.

ETA MAE cũng cần được báo cùng recall và số ca không có ETA. Một phương pháp chỉ cảnh báo các ca dễ có thể có ETA đẹp nhưng bỏ qua nhiều tình huống cần quan tâm.

6.5 Bảo toàn thứ tự thời gian cả trong học và chấm điểm

Khoảng loại trừ 60 phút ở ranh giới validation là bài học có thể tái sử dụng cho dự báo đa bước: ranh giới phải xét toàn bộ vùng target. Tương tự, nhật ký dự báo phải được lưu trước khi dữ liệu tương lai đến, và phép chấm không được chọn các bản sửa muộn để làm kết quả tốt hơn.

Các cửa sổ chồng lấn giúp tăng số mẫu huấn luyện nhưng không tăng tương ứng số tình huống độc lập. Báo cáo chất lượng nên bổ sung đánh giá theo đợt sự kiện, ngày thu và thời điểm khởi phát; đồng thời công bố tỷ lệ thời gian hệ thống phải tạm ngừng vì dữ liệu không đủ.

6.6 Quản lý phiên bản là một phần của độ tin cậy

Thư mục dự án lưu cả đề xuất ban đầu, báo cáo total 30 phút, bản chuyển sang WTI 60 phút, audit và các sửa đổi vận hành. Đọc một báo cáo cũ mà không đối chiếu code có thể dẫn đến mô tả sai target, ngưỡng, thời điểm ghi timestamp, cách dự báo tạm thời hoặc khả năng lưu dữ liệu.

Mỗi kết quả về sau nên gắn với mã nguồn, dữ liệu, model, cấu hình và môi trường cụ thể. Metadata hiện có đã là nền tảng tốt; cần tiếp tục đảm bảo mọi thay đổi ở logic tạm thời hoặc điều kiện đầu vào đều có đánh giá tương ứng, thay vì dùng lại điểm số của phiên bản trước.

6.7 Ưu tiên cho vòng phát triển tiếp theo

Bảng 15: Các ưu tiên và tiêu chí hoàn thành cho vòng phát triển tiếp theo

Ưu tiên	Việc cần làm	Bằng chứng hoàn thành cần có
1	Thu thêm nhiều ngày và lưu camera ID, phiên bản detector, cấu hình vùng quan tâm	Dữ liệu có nguồn gốc rõ ràng, bao phủ các thời đoạn và điều kiện quan sát khác nhau
2	Gán nhãn một tập ảnh và trạng thái giao thông độc lập	Sai số đếm/phân loại theo lớp, điều kiện ảnh và đánh giá ngưỡng với nhãn thực
3	Đồng nhất tiêu chí số mẫu giữa train, replay và live	Backtest phản ánh đúng điều kiện được phép dự báo, kèm tỷ lệ bao phủ
4	Chấm lại nhánh tạm thời đang dùng trên dữ liệu mới	So sánh cùng origin giữa tham chiếu thuần, hiệu chỉnh mức/xu hướng và nhánh model
5	Đánh giá cảnh báo theo sự kiện và thời điểm khởi phát	Báo nhầm/giờ, bỏ sót đợt, lead time, ETA trên tập chung và các trường hợp không cảnh báo
6	Đo khả năng vận hành trên máy triển khai	Độ trễ, bộ nhớ, ảnh hưởng khi đổi camera và tỷ lệ thời gian đủ dữ liệu

Hệ thống đã tạo được nền tảng để kiểm tra những câu hỏi này bằng dữ liệu: có quy trình thu, feature dùng chung, baseline, model đa bước và nhật ký dự báo. Giá trị của vòng phát triển tiếp theo nằm ở việc bổ sung bằng chứng về phép đo và hiệu quả cảnh báo, trước khi tăng độ phức tạp của mô hình.

A Mã nguồn (Source Codes)

A.1 Các thư viện được sử dụng

```
import requests
import cv2
import numpy as np
import time

```

A.2 Get_frame.py

```
def get_traffic_image(name="Camera 1"):
    global cam_id
    timestamp = int(time.time() * 1000)
    url =
     ↪  f"https://giaothong.hochiminhcity.gov.vn/render/ImageHandler.ashx?id={cam_id[name]}&t={tim

    headers = {
        "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36",
        "Referer": "https://giaothong.hochiminhcity.gov.vn/Map.aspx"
    }

    try:
        response = requests.get(url, headers=headers, timeout=5)
        if response.status_code == 200:
            img_array = np.asarray(bytearray(response.content), dtype=np.uint8)
            frame = cv2.imdecode(img_array, cv2.IMREAD_COLOR)
            return frame
        else:
            print(f"Server response error: {response.status_code}")
    except requests.exceptions.RequestException as e:
        print(f"Network error: {e}")

    return None
```

A.3 Yolo_detect.py

```
def callback(image_slice: np.ndarray) -> sv.Detections:
    result = model(image_slice)[0]
    return sv.Detections.from_ultralytics(result)

def image_processing(frame):
    slicer = sv.InferenceSlicer(callback=callback, slice_wh=(256, 256))
    detections = slicer(frame)

    # Đếm theo class ID của YOLO
    class_ids = detections.class_id

    person_count = np.sum(class_ids == 0)
    car_count = np.sum(class_ids == 2)
    motorbike_count = np.sum(class_ids == 3)
    bus_count = np.sum(class_ids == 5)
```

```
    truck_count = np.sum(class_ids == 7)
    total_vehicles = car_count + motorbike_count + bus_count + truck_count
    total_objects = len(class_ids)

    print(f"Person: {person_count}")
    print(f"Car: {car_count}")
    print(f"Motorbike: {motorbike_count}")
    print(f"Bus: {bus_count}")
    print(f"Truck: {truck_count}")
    print(f"Total vehicles: {total_vehicles}")
    print(f"Total objects detected: {total_objects}")

    # Weighted Traffic Impact (WTI)
    car_w = 4
    motorbike_w = 1
    bus_w = 7
    truck_w = 6

    weighted_traffic_impact = (
            int(car_count) * car_w
            + int(motorbike_count) * motorbike_w
            + int(bus_count) * bus_w
            + int(truck_count) * truck_w
    )

    weighted_traffic_impact_norm = (
        weighted_traffic_impact / total_vehicles if total_vehicles > 0 else 0.0
    )

    box_annotator = sv.BoxAnnotator(thickness=1)

    annotated_frame = box_annotator.annotate(
        scene=frame.copy(),
        detections=detections
    )

    current_time = datetime.now().strftime("%Y-%m-%d %H:%M:%S")
    cv2.putText(annotated_frame, f"{current_time}", (15, 35),
                cv2.FONT_HERSHEY_SIMPLEX, 1, (0, 255, 255), 2)

    return annotated_frame, person_count, car_count, motorbike_count, bus_count,
     ↪  truck_count, total_vehicles, weighted_traffic_impact, weighted_traffic_impact_norm
```